SAE S2.02 : Exploration algorithmique

Il s'agit dans cette SAE d'essayer de constater le phénomène de réchauffement climatique à partir des données recueillies lors de votre précédente SAE. Afin d'exploiter au mieux ces données qui sont considérables en quantité, une étude sur la représentation de plusieurs types de structures de données sera préalablement initiée. L'objectif est de déterminer quelle structure semble être la plus adaptée pour répondre efficacement à un certain nombre de questions comme :

- Le réchauffement climatique est-il global ?
- Le réchauffement est-il similaire dans toutes les stations ?
- Est-ce que ce réchauffement est le même sur tous les mois ou faut-il les différencier ? Est-ce que la saison est importante ?
- Y-a-t-il des années exceptionnelles ? L'interprétation des résultats est-elle la même si on ne prend pas en compte ces années exceptionnelles ?
- …

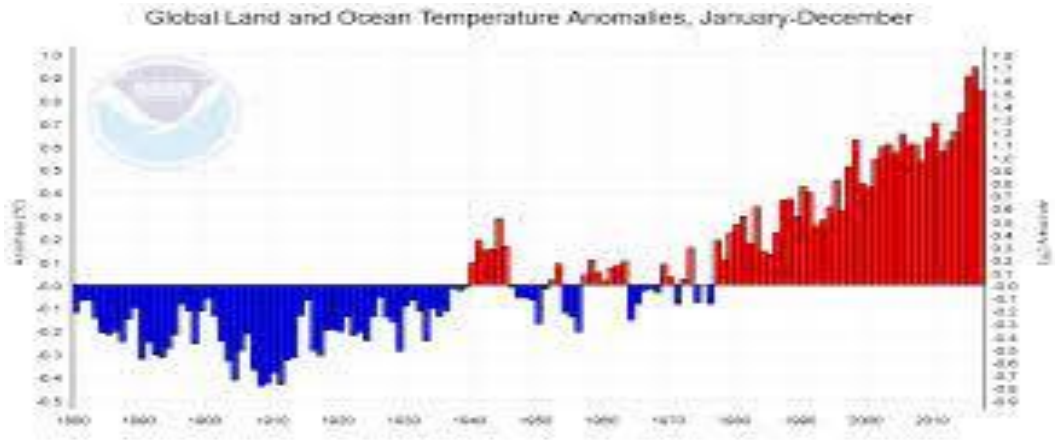

Vous devrez bien entendu rendre à la fois votre solution Visual épurée des fichiers non nécessaires **(les répertoires data et data2 utilisées dans la partie 2 ne sont pas à rendre)** ainsi qu'un compte-rendu le plus complet possible avec en première page la liste de toutes les fonctionnalités que vous aurez eu le temps d'implémenter. Ensuite sur les pages suivantes vous répondrez aux questions demandées au fur à mesure du déroulé de ce sujet. Enfin dans une dernière partie vous exposerez les principales difficultés rencontrées et la conclusion à votre travail d'analyse des données.

Partie 1 : Étude de structures de données : listes chaînées, arbres binaires

1. *Préambule*

Pour chacune des fonctions membres de vos structures de données, il est demandé d'évaluer (sans démonstration) la complexité de celles-ci. Vous indiquerez celles-ci en commentaires dans les fichiers d'entêtes comme dans les 2 premiers exemples donnés pour *Liste.h*. Bien évidemment, vous compléterez ces estimations de complexités au fur et à mesure de votre implémentation.

On vous rappelle les principales classes de complexité que nous rencontrons en informatique :

O(1) : complexité constante ne dépendant pas de n (quelques opérations)

O(n) : n opérations à un facteur multiplicatif près (ainsi 0(n)=O(3n)=O(n/2)…) (typiquement une boucle sur les n éléments)

O(log(n)) : lorsque la taille n du problème est divisée par 2 à chaque étape (par exemple quand vous jouez au jeu de la recherche d'un nombre entre 1 et 1000 et que l'on vous répond plus petit ou plus grand : vous proposez 500 pour éliminer la moitié des nombres…)

$O(n^2)$: typiquement une boucle imbriquée dans une autre (exemples : tris simples)

O(n log(n)) : (exemples : tris performants)

Lorsque n devient grand, on a (<< veut dire « très inférieur ») :

$$\mathbf{O(1) << O(\log(n)) << O(n) << O(n \log(n)) << O(n^2) \ldots}$$

2. *Structures de données*

a. *Liste chaînée simple*

La classe Liste vous est fournie. Seule la fonction membre ajoute_cellule_en_queue est encore à implémenter par vos soins. Il est important de comprendre la structure abstraite d'une liste et les schémas qui suivent sont là pour vous aider et doivent être mis en parallèle avec les lignes de code associées, en particulier pour la suppression.

- Représentation schématisée d'une liste chaînée simple

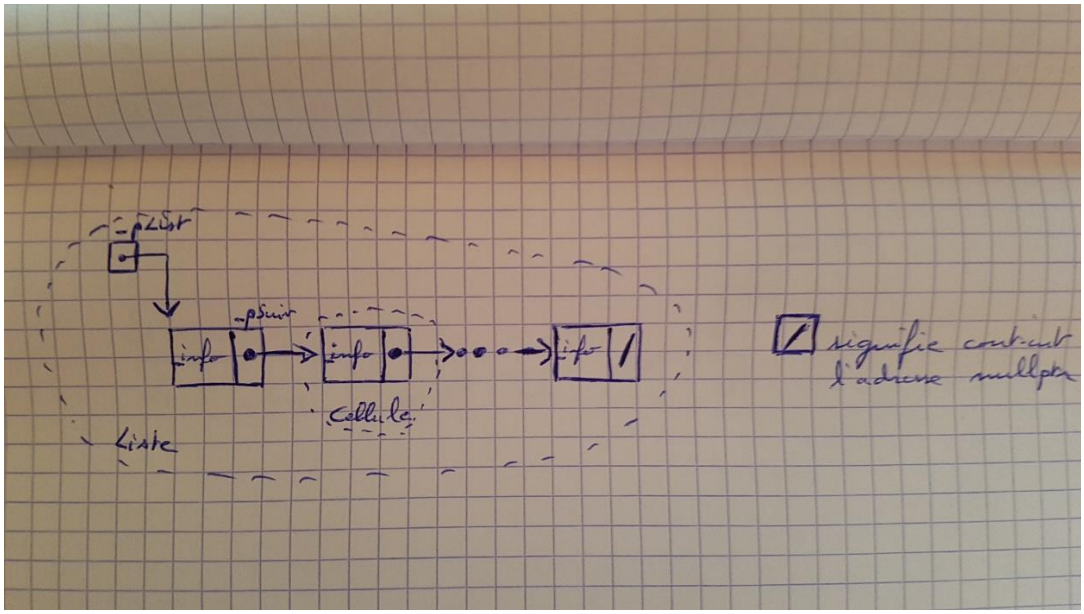

- Suppression dans une liste chaînée simple

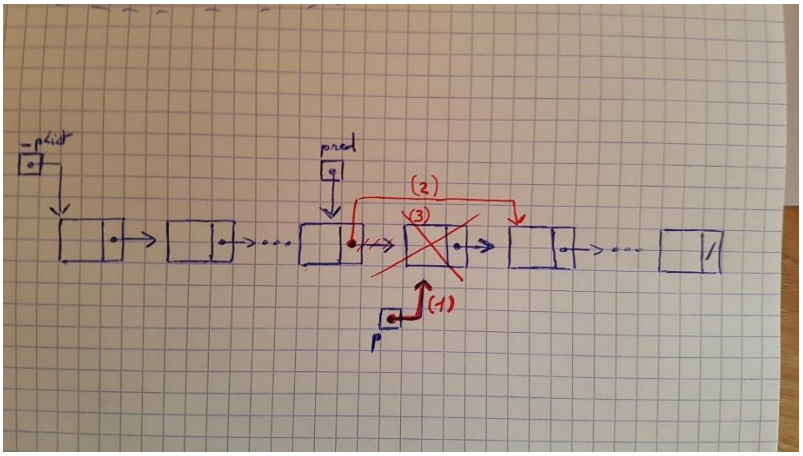

Figure 1 : Suppression cas général

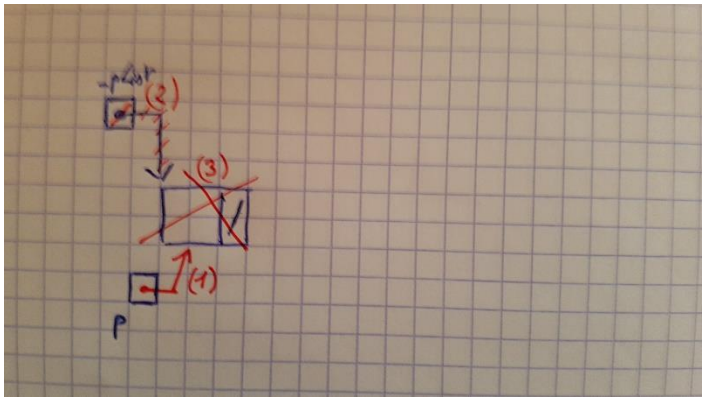

Figure 2 : cas particulier : suppression en tête de liste

b. Liste chaînée bi-directionnelle

- Représentation schématisée d'une liste chaînée bi-directionnelle

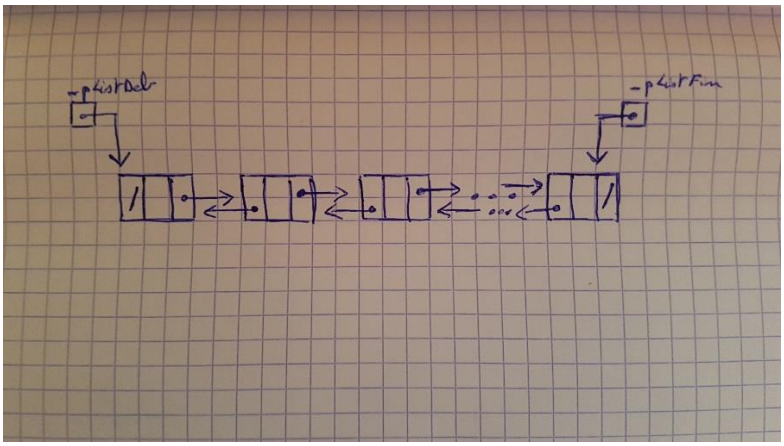

Figure 3: Liste bi-directionnelle

En vous inspirant de la classe *Liste* , implémenter les fonctions membres de la classe ListeB (liste bi-directionnelle). Faire les schémas comme sur l'exemple de la suppression (fig 1 et 2) pour les fonctions *ajoute_cellule_en_tete, ajoute_cellule_en queue et supprime_cellule*.

c. Arbre binaire

- Représentation schématisée d'un arbre binaire

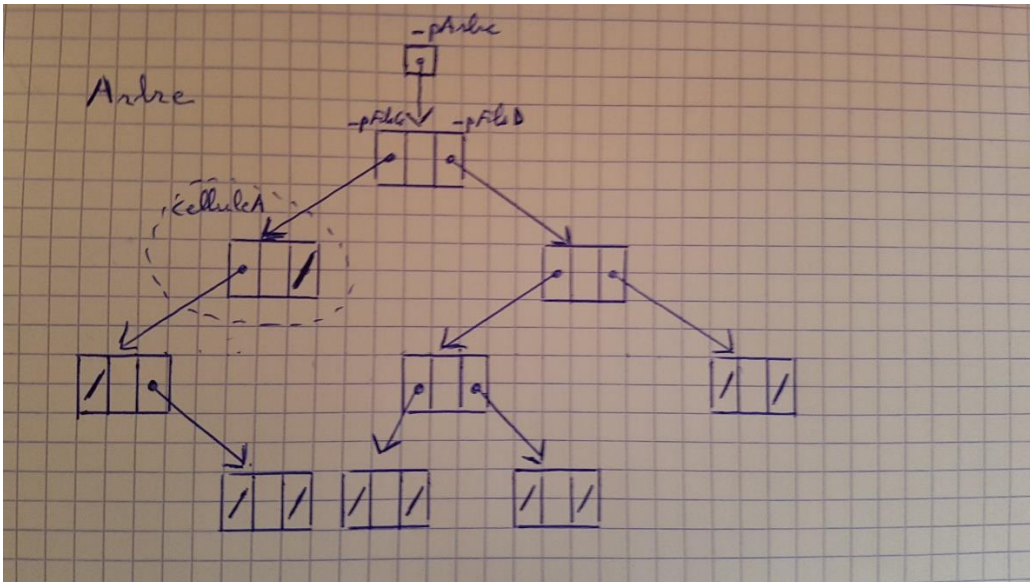

Figure 4 : Un exemple d'arbre

La classe Arbre représentera des arbres binaires de recherche (ABR). On commencera par comprendre à l'aide d'internet ce qu'est un ABR, un parcours préfixé, infixé, postfixé et on implémentera ensuite les fonctions membres non déjà implémentées (n'oubliez pas d'évaluer les complexités : cf Préambule).

La fonction membre donnée ajoute_cellule est à commenter.

Certains pseudo-algorithmes ou indications sont donnés ci-après pour vous aider. Les fonctions récursives sont souvent utilisées avec les arbres car souvent plus faciles à écrire…

Fonction *nbelem* :

Si arbre vide alors retourner 0

Sinon retourner 1 + nbelem(arbregauche)+nbelem(arbredroit)

Fonction *nbfeuille* :

Un nœud est une feuille si celui-ci n'a ni fils_gauche, ni fils_droit.

Fonction *hauteur* :

La hauteur d'un arbre vide vaut 0

sinon elle vaut 1 + max(hauteur(arbregauche), hauteur(arbredroit))

Vous écrirez bien évidemment un programme principal permettant de tester les fonctions et structures de données. N'oubliez pas de remplir votre compte-rendu avec pour chaque structure de données les complexités de toutes les fonctions.

Partie 2 : Exploitation de la base de données

Bien évidemment l'attribut *_info* des structures vues dans la 1ère partie n'est pas restreint à être un entier et peut être de type quelconque… Seule est nécessaire une relation d'ordre pour pouvoir exploiter les ABR.

Vous utiliserez maintenant la solution de la partie 2 dans laquelle vous exploiterez les fichiers de données météo fournis (répertoire data). L'implémentation de la structure de données suivra le schéma suivant :

```
struct CelluleStation
{
    int _ID; // numero d'identification de la station
    std::array<Arbre, 12> tab_arbres; // 1 arbre binaire de recherche par mois de
l'annee
    CelluleStation* _pSuiv;
    CelluleStation* _pPred;
} ;


struct CelluleArbre {
      float _deltaT;     //deltaT : différence de T entre _annee et _annee+1
(T_annee+1 - T_annee) pour le mois considere

      int _annee;        // année du mois en cours
      float _tempMois;   // température moyenne du mois en cours
      float _tSigmaMois; // écart type moyen de la température du mois en cours
      CelluleArbre* _pFilsG;
      CelluleArbre* _pFilsD;

};
```

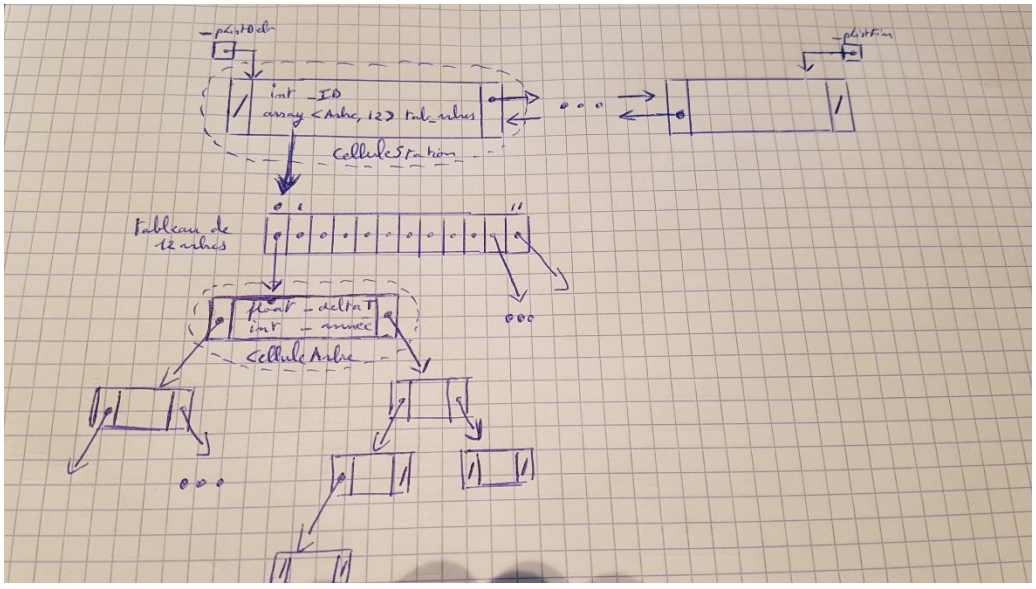

Chaque arbre sera un ABR ordonné par rapport à la clé *_deltaT*, qui est la différence de température entre 2 années consécutives pour un mois fixé.
Mathématiquement, ce deltaT va correspondre à une approximation de la dérivée.

- ## Partie 2-1 : Construction de la structure arborescente :

Remarque : si vous n'avez pas réussi à implémenter correctement la liste bi-directionnelle dans la partie 1, vous pourrez utiliser une liste chaînée simple à la place. Le fichier d'entête de la classe SAE_Data contiendra au minimum ceci :

```
class SAE_Datas_Heat {
    // Private Datas
    std::vector<std::map<int, std::pair<float,float> > > _vRawData;
    ListeStation _lListeStations;

    // Private Functions
    std::string readFileIntoString(const std::string& path)const;
    std::vector<std::string> listAllFiles()const;
    std::map<int, std::pair<float, float> > parseContentFile(std::string filename);
    void convertDataInList();
    Arbre calculDeltaT(size_t mois, const std::vector<float>& vTmoyStation, const std::vector<float>& vTSigmaStation);

public:
    // Public Functions
    SAE_Datas_Heat();
    size_t nbMonths()const;
    size_t nbStations()const { return _lListeStations.nbelem(); }
    const ListeStation& getListeStation()const { return _lListeStations; }
};
```

Il s'agit maintenant de remplir cette structure. La fonction `parseContentFile(std::string filename)` permet de lire les données d'un fichiers CSV de la SAE 2.4. Chaque fichier correspond à un mois de données. La première ligne contient les entêtes des colonnes que la fonction enlève. Les autres lignes contiennent les données proprement dites.

Vous obtiendrez un vecteur de 360 éléments (`std::vector<std::pair<float,float>>`) contenant toutes les données pour tous les mois (nous ne nous intéresserons aux températures moyennes du mois et à l'écart-type fournis dans la paire). Ensuite un élément est représenté en C++ par une map indexée par un index correspondant à l'ID de la station (un int par exemple 7005) et pour chaque index vous aurez un vecteur de paires contenant les données.

Voici un schéma nous l'espérons plus explicite :

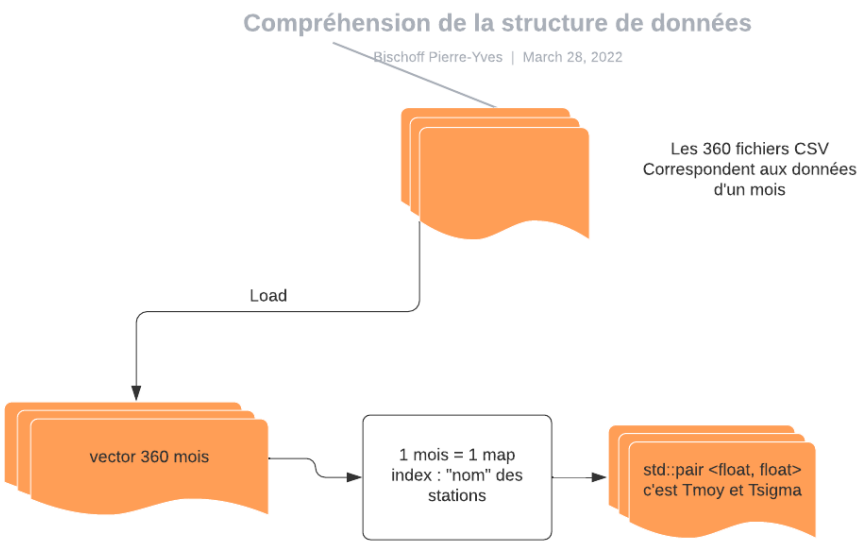

Les fonctions de remplissage de la structure vous sont données, la base est alors épurée et ne contient malheureusement plus que 21 stations complètes.

• Partie 2.2 : exploitation de la structure arborescente :

Cette partie, bien que petite en nombre de lignes du sujet, **représentera près de la moitié des points de votre SAE.**

Maintenant que votre structure de données est remplie, vous allez pouvoir définir vos propres fonctions d'exploitation de la base dans *Traitement.cpp* afin d'en tirer un maximum d'informations. **Vous expliquerez en commentaires ce que sont censés faire chacune de vos fonctions, et les résultats attendus. Formulez explicitement la question à laquelle l'exploitation de votre fonction cherche à répondre ? N'oubliez pas de remplir le compte-rendu avec des exemples illustrés.**

Nous vous laissons ici assez libre dans les fonctions que vous allez mettre en œuvre. Posez-vous les bonnes questions, soyez pertinent, implémentez vos fonctions et interprétez au mieux les résultats obtenus. Faut-il ensuite faire des ajustements et de quel ordre ?

Vous pourrez ainsi être amené à vous demander des choses comme : que traduirait le fait que, lors d'un parcours infixé de mon arbre de recherche, l'affichage des années correspondantes se retrouvent en ordre croissant (ou quasi croissant) ? (etc…)

Pour l'interprétation des résultats il faut savoir qu'en météorologie on travaille au minimum sur des durées de 10 ans pour atténuer les variations annuelles qui sont assez importantes. Vous serez probablement amené à utiliser un tableau intermédiaire (indexé suivant les années) pour répondre à certaines questions.

• Partie 3 : Base de données non intègre :

Il se trouve que les données de la base ont été préalablement traitées par nos soins afin que la base soit intègre (sans valeurs aberrantes, ou absentes).

On vous demande de créer un nouveau projet qui reprendra l'ensemble de votre code précédant et qui exploitera les données de la base data2 (base non intègre).

Il vous est demandé de rendre intègre les données dans votre programme. Vous pourrez donc être amené à supprimer de votre structure des arbres (ayant des valeurs de températures aberrantes) ou même des postes de votre liste. Il est important de retirer ces erreurs afin de ne pas perturber fortement vos résultats et leurs interprétations.

Voici les règles définies pour épurer la base de données :

On considérera qu'une valeur deltaT est aberrante si la valeur absolue du deltaT est >25.0

- Si un arbre possède 1 ou 2 valeurs deltaT aberrantes on enlève ces nœuds de l'arbre.
- Si un arbre (pour un mois donné) possède 3 ou plus valeurs aberrantes on supprime l'arbre.
- Si on doit enlever 2 ou plus arbres à une station, on supprime la station.

En conclusion est-ce que les résultats redeviennent plus conforme aux résultats de la partie 2 ?